National Tsing Hua University
Fall 2024 11310IPT 553000
Deep Learning in Biomedical Optical Imaging
Homework 4
112011524 劉翔緯

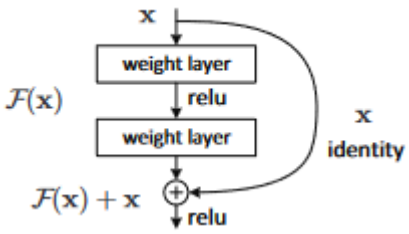

Task A: Model Selection

1. ResNet18（Residual Network）
   透過 Residual Blocks 包含一個 Shortcut Connection，也就是一個將輸入直接連接到輸出的路徑，減少深層網路中梯度消失的風險。因此可以使他堆疊很深仍然保持良好的性能。並且其 pre-trained 和 transfer learning 有很好的能力，特別是在影像分類上有出色的準確性。
   缺點是參數量較多，計算資源需求較高，若是網路較深，訓練 ResNet 也需要更多的計算時間和資源，所以我選擇較小的 ResNet18，減少計算資源的用量。
2. SqueezeNet
   使用多個 Fire Module 堆疊，每個 Fire Module 包含兩部分：壓縮（Squeeze）層和擴張（Expand）層。壓縮層：使用 1x1 卷積層來減少特徵圖通道數，從而降低計算量。擴張層：在壓縮後，擴張層包含 1x1 和 3x3 卷積，將壓縮後的特徵圖進行擴展，生成更多的特徵。此方法降低了整個模型的參數數量，適合計算量小的方法。能力大約跟 AlexNet 差不多，但有非常少的存儲需求與計算成本。

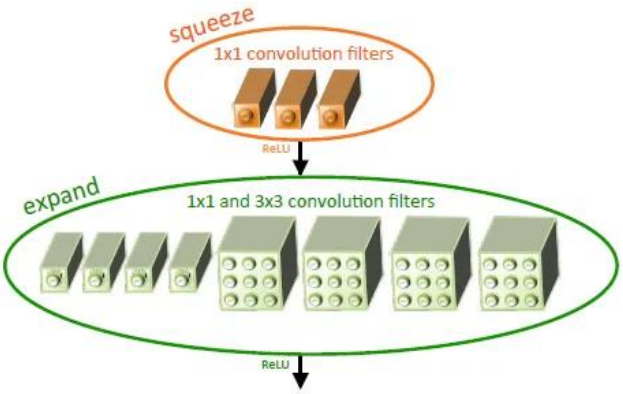

Task B: Fine-tuning the ConvNet

Data augmentation

```
train_transform = transforms.Compose([
transforms.Resize((256, 256), interpolation=InterpolationMode.BICUBIC),
transforms.CenterCrop(224),
```

transforms.Grayscale(num_output_channels=3),
transforms.ColorJitter(brightness=0.2, contrast=0.2, saturation=0.2, hue=0.1),
transforms.ToTensor(),
transforms.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225])
])

在預處理上，調整成 224、以符合 models 的標準，加上 ColorJitter 隨機調整圖像的亮度、對比度、飽和度和色相，提升模型適應與數據，減少 overfitting。

1. ResNet18（Residual Network）(epoch=10)
   accuracy 提高得非常快，不過因為其 net 複雜度使其也很容易 overfitting，即使我調整了 lr = 0.0001；weight_decay = 0.002；Dropout(p=0.5)；還是會 Overfitting。可能要更大量的 dataset 才能有更好的效果。

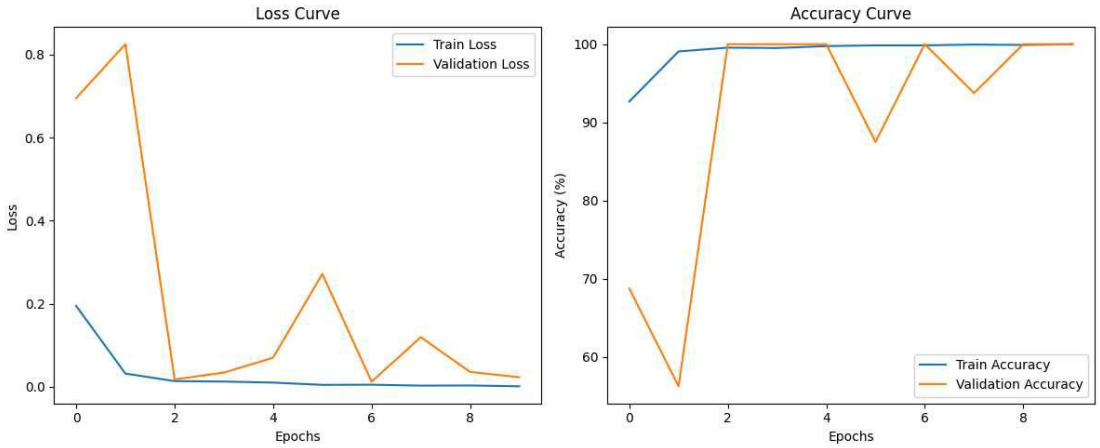

2. SqueezeNet (epoch=10)
   Accuracy 沒有像 ResNet 那樣高，但可以穩定到可以接受的程度，在這種小 dataset 上是有效果的。

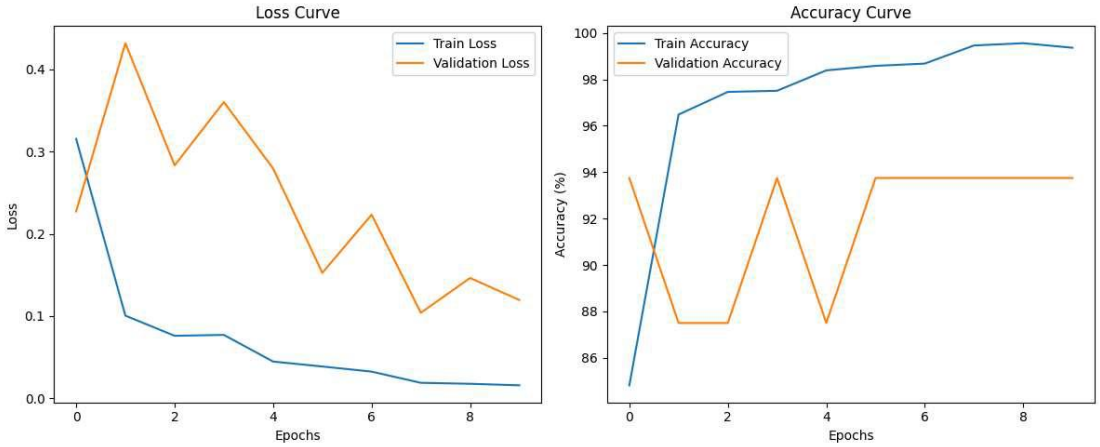

Task C: ConvNet as Fixed Feature Extractor

```
# Freeze all convolutional layers to use as a fixed feature extractor
for param in model.parameters():
    param.requires_grad = False
```

由於凍結所有層，僅訓練最後的全連接層，使其減少了訓練量，也避掉了 overfitting 的狀況。不過也因此不好達到高 accuracy，性能變差。

1. ResNet18（Residual Network）

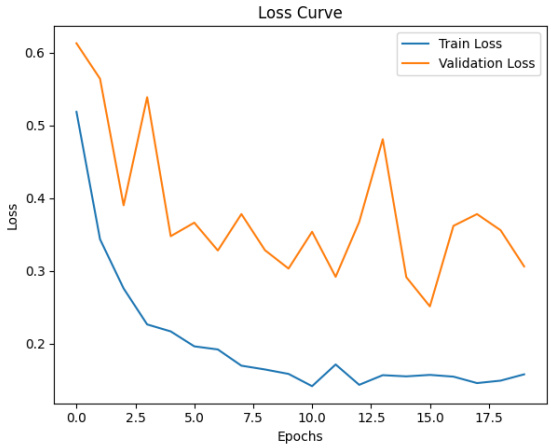

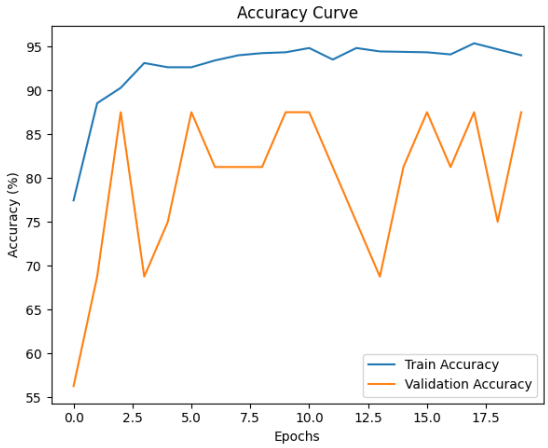

2. SqueezeNet

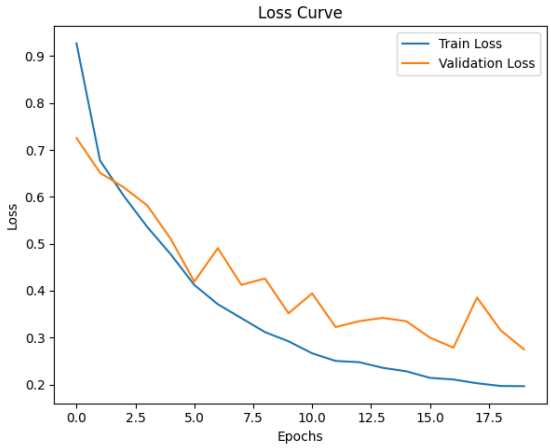

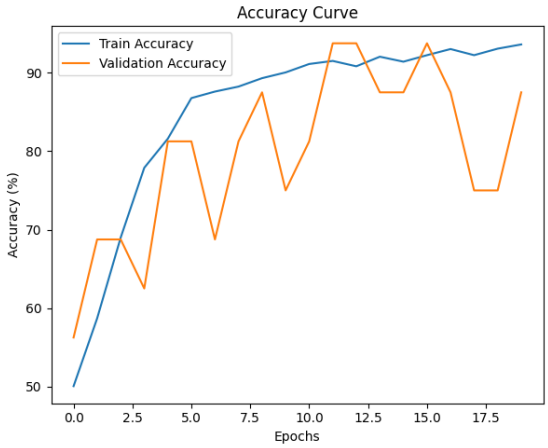

Task D: Comparison and Analysis

透過 taskB、C 圖可以了解，在 Fine-tuning 下，ResNet 會有較好的 performance，但由於這次的 dataset 並不大量，使得其太過 overfitting，而 SqueezeNet 則可以在小 data 下發揮較穩定。在 Fixed Feature Extractor 下，受限於預訓練數據集的特性，效能會因此下降，SqueezeNet 保持一定的性能，ResNet 則有其深度結構來輔助穩定它的效能。在這兩者間我認為因為 dataset 較小因此 SqueezeNet 發揮都較好，better adaptability；不過若是在大量的 data 下 ResNet 靠著龐大的深度結構在 Fine-tuning 理論上會有更好的效能。

Task E: Test Dataset Analysis

1. ResNet18（Residual Network）

   Fine-tuning

   Test Accuracy: 91.09%

   Test Loss: 0.3518

   Fixed Feature Extractor

   Test Accuracy: 84.43%

   Test Loss: 0.3584

2. SqueezeNet

   Fine-tuning

   Test Accuracy: 88.28%

   Test Loss: 0.3308

   Fixed Feature Extractor

   Test Accuracy: 89.43%

   Test Loss: 0.2952

HW3

Test Accuracy: 83.93%

Test Loss: 0.3490

在 test 分析上，ResNet 有很好的 Test Accuracy，但由於其在這個 dataset overfitting，因此不適合；若是透過 Fixed Feature Extractor 則可以稍微減少他 overfitting 的影響，但 ResNet 還是適合大 data 的環境。而這次 HW 的 dataset 量就非常適合 SqueezeNet 這種設計就是為了輕量 data 的 model，可以達到降低成本與效能兼具，在 Test Accuracy 也有不低於 HW3 的準確率。其中可以看出數據集的大小和多樣性會影響模型的性能。如果測試數據集的樣本數量不足，或者樣本的多樣性不夠，則可能無法充分評估模型的真實性能。因此，為了提高模型在測試數據集上的表現，在訓練過程中使用數據增強，增加訓練數據的多樣性，並確保訓練和測試數據集的分佈相似，可以提高模型的泛化能力。